

MOOC 3: Detect and Mitigate Ethical Risks

Phát hiện và Giảm thiểu các Rủi ro Đạo đức trong Mô hình Thuật toán & Dữ liệu

Chương trình: CEET (CertNexus)

Tác giả / Sở hữu: vibook-phuchthodev

Cấp độ: Chuyên gia (Practitioner)

Tóm tắt khóa học: MOOC 3 tập trung sâu vào mặt kỹ thuật và quy trình để kiểm soát rủi ro định kiến (bias), tính minh bạch (explainability) và bảo mật thuật toán. Học viên được học cách áp dụng các thước đo toán học, thuật toán can thiệp giảm thiểu rủi ro và các công cụ thực tế như IBM AI Fairness 360 & Fairlearn.

1. Phân Tích Chi Tiết Nội Dung 5 Mô-đun

Mô-đun 1: Đo lường & Định lượng Định kiến (Quantifying & Measuring Bias)

Phương pháp định lượng định kiến trong tập dữ liệu và kết quả dự báo của mô hình:

- Chỉ số Tác động Bất bình đẳng (Disparate Impact - DI):** Đo lường tỉ lệ nhận kết quả tích cực giữa nhóm nhạy cảm và nhóm đối chứng (quy tắc 80%).
- Đồng nhất Nhân khẩu học (Demographic Parity):** Đảm bảo tỷ lệ dự báo tích cực là như nhau trên các phân khúc người dùng.
- Cân bằng Tỷ lệ Rủi ro (Equalized Odds & Equal Opportunity):** Đánh giá sự bình đẳng dựa trên Tỷ lệ Dương tính Giả (FPR) và Âm tính Giả (FNR).

Mô-đun 2: Chiến lược Can thiệp & Giảm thiểu (Bias Mitigation Strategies)

Các giải pháp kỹ thuật can thiệp ở 3 giai đoạn của đường ống học máy (ML Pipeline):

- Tiền xử lý (Pre-processing):** Thuật toán Re-weighting, Disparate Impact Remover điều chỉnh dữ liệu đầu vào.
- Trong xử lý (In-processing):** Tích hợp ràng buộc công bằng trực tiếp vào hàm mất mát (Adversarial Debiasing).
- Hậu xử lý (Post-processing):** Tối ưu hóa ngưỡng quyết định (Threshold Optimizer) sau khi mô hình đã huấn luyện xong.
- Đánh đổi Fairness - Accuracy:** Phân tích và quản lý mối quan hệ đánh đổi giữa độ chính xác và tính công bằng.

Mô-đun 3: Trí tuệ Nhân tạo Giải thích được (Explainable AI - XAI)

- Công cụ và kỹ thuật bạch hóa mô hình hộp đen (Black-box models):
- **LIME (Local Interpretable Model-agnostic Explanations):** Giải thích dự báo cá thể bằng mô hình xấp xỉ tuyến tính cục bộ.
 - **SHAP (Shapley Additive exPlanations):** Tính toán đóng góp của từng thuộc tính dựa trên lý thuyết trò chơi.
 - **Giải thích Phản thực tế (Counterfactual Explanations):** Đưa ra các gợi ý thay đổi tối thiểu để đảo ngược kết quả dự báo tiêu cực.

Mô-đun 4: Độ bền vững & Rủi ro An ninh (Robustness & Security Risks)

- Bảo vệ mô hình trước các cuộc tấn công kỹ thuật số tinh vi:
- **Tấn công Đầu độc Dữ liệu (Data Poisoning Attacks):** Cố tình chèn dữ liệu sai lệch để làm biến dạng mô hình.
 - **Tấn công Đối kháng (Adversarial Attacks):** Thay đổi nhỏ ở dữ liệu đầu vào làm sai lệch kết quả dự báo.
 - **Trích xuất Mô hình & Dữ liệu (Model Inversion & Membership Inference):** Nguy cơ khôi phục dữ liệu nhạy cảm từ kết quả đầu ra.

Mô-đun 5: Dự án Thực hành Kiểm toán Đạo đức (Risk Mitigation Capstone)

- Áp dụng bộ công cụ thực tế vào kiểm toán toàn diện:
- **Thực hành IBM AI Fairness 360 & Fairlearn:** Xây dựng quy trình phát hiện và triệt tiêu định kiến tự động.
 - **Lập Báo cáo Bảng điểm Đạo đức (Ethical Scorecard):** Trình bày phát hiện rủi ro cho ban quản trị và các bên liên quan.
 - **Thiết lập Quy trình Giám sát Đột biến (Continuous Monitoring):** Cảnh báo khi mô hình bị lệch chuẩn theo thời gian.

2. Bảng Tóm Tắt 3 Giai Đoạn Can Thiệp Định Kiến (Debiasing)

Giai đoạn	Phương pháp / Thuật toán	Ưu điểm nổi bật
Pre-processing	Re-weighting, Disparate Impact Remover	Mô hình hóa độc lập, không thay đổi thuật toán huấn luyện
In-processing	Adversarial Debiasing, Prejudice Remover	Cân bằng tối ưu nhất giữa Accuracy và Fairness
Post-processing	Reject Option Classification, Threshold Optimizer	Áp dụng trực tiếp vào mô hình đã huấn luyện sẵn (Black-box)

Tài liệu tóm tắt MOOC 3 thuộc bản quyền của vibook-phucthodev. Được tổng hợp dựa trên khung chuẩn đào tạo CertNexus CEET.